데이터분석캡스톤디자인 · 개발 참고자료

AI Stock Assistant

정형데이터 + 뉴스 멀티모달 Classification · Portfolio Optimization · GPT(XAI) 통합 개발 문서

KOSPI 전체 종목 대상 · Classification · Portfolio Optimization · GPT

2021105696 박성준 · 2022105470 신희재

발표자료 내용에 XAI(SHAP · Integrated Gradients · Ablation) 구현 계획과 레포 구조를 더해 개발하면서 보기 편하게 정리한 자료입니다.

01 · OVERVIEW

프로젝트 개요

국내 주식시장, 그중에서도 KOSPI 전체 종목을 대상으로 개별 종목의 단기 급락 위험을 예측하고, 이를 반영한 사용자 맞춤형 포트폴리오를 추천하는 서비스입니다. 단순 가격 예측이 아니라, 급락 위험을 정량화하고 그 정보를 자산배분 의사결정에 직접 반영하는 것이 핵심입니다.

구성요소	역할
Classification	종목별 급락 확률을 정량적으로 예측
Portfolio Optimization	수익 · 위험 · 급락확률 · 위험성향을 반영해 비중 계산
GPT	뉴스 · 공시 원문을 해석하고, Classification · Optimization의 근거(XAI)를 종합해 추천 사유를 설명

기획 배경

뉴스로 주식 위험을 예측한다는 아이디어에서 출발 → 주가 · 뉴스 데이터를 함께 활용하는 방향으로 발전 → 사용자가 직접 쓰는 웹 서비스로 구현하는 것을 목표로 확정.

02 · SCOPE & FEATURES

분석 대상 & 핵심 기능

분석 대상 — KOSPI 전체 종목

초기: KOSPI 시가총액 상위 50개 종목 → 더 다양한 종목 데이터 확보 및 서비스 활용 범위 확대를 위해 전체 종목으로 확대하되, 신규 상장이나 상장 폐지 위험이 있는 종목은 검열.

핵심 기능	설명
① 급락위험 예측	가격 · 수급 · 기술지표 · 재무 · 공시 · 뉴스 feature로 단기 급락 확률 산출
② 포트폴리오 최적화	수익률 · 위험 · 급락확률 · 위험성향을 반영해 종목별 비중 계산
③ 뉴스 · 공시 해석 (GPT)	원문을 감성 · 영향도 · 위험도 · 이벤트유형으로 구조화
④ 추천 결과 제공	최종 포트폴리오와 추천 사유(XAI 근거 포함)를 React 화면에 제시

03 · SYSTEM

시스템 구조 — 데이터 → 서비스 파이프라인

교수님 피드백 이후 Classification · Optimization · GPT를 하나의 파이프라인으로 연결하기 위해 GPT 설명 단계 앞에 XAI 단계를 추가했고, 급락 정답 레이블을 만드는 Label 단계도 Feature Engineering과 나란히 넣었습니다.

단계	이름	설명
01	데이터 수집	한투 API · OpenDART · 네이버뉴스
02	PostgreSQL 저장	시세 · 재무 · 수급 · 공시 · 뉴스
03	Feature Engineering	기술지표 · 수급누적 · 재무비율 (02의 병렬 branch)
04	Label 생성	급락 정답 레이블 — ai/labeling/build_crash_label.py (02의 병렬 branch)
05	GPT 구조화	sentiment · impact · risk_score (02의 병렬 branch)
06	Classification · Optimization	급락확률 예측 + 비중 계산 (멀티모달, split.py로 train/test 분리)
07	XAI	SHAP · Integrated Gradients · Ablation → GPT 설명 생성
08	React 화면 (Vercel)	추천 포트폴리오 + 추천 사유(XAI 근거 포함)

※ Feature Engineering · Label 생성 · GPT 구조화는 저장된 데이터를 각자 병렬 처리하며, 세 결과가 모두 Classification에 입력됩니다.

※ Label은 기준일 이후 가격을 봐야 만들 수 있어서 Feature 계산과는 파일을 분리했습니다. train/test는 `ai/classification/split.py` 하나로만 나누고, 겹치는지는 `tests/test_split.py`로 확인합니다.

※ Python 기반 AI 학습 · 추론 환경을 배포와 분리할지는 별도로 검토 중입니다.

04 · DATA SOURCES

데이터 수집 계획 — 출처 우선순위

1순위 — 핵심 데이터

출처	수집 내용
한국투자증권 Open API	OHLCV · 수급 · 실시간 체결
OpenDART	공시원문 · 재무 · 지분정보
네이버 뉴스 검색 API	뉴스 제목 · 본문 · 발행시간

2순위 — 보완 데이터

출처	수집 내용
KRX Open API	지수 · 시장정보
KIND	거래소 공시 보완

3순위 — FnGuide · FnSpace, 한국은행 ECOS (고도화 단계에서 필요성 재판단) / 보조 — 웹 스크래핑(공식 API 보완 시에만)

수집 데이터 항목

- ① 주가 · 거래 ② 투자자수급 ③ 기술지표 ④ 재무 · 밸류에이션 ⑤ 공시 ⑥ 뉴스 ⑦ 시장 · 거시

05 · AI DESIGN

AI 구현 방식 — 역할 분리

Classification	Portfolio Optimizer	GPT
급락 확률 예측 - 급락 정의: 5거래일 내 종가 -10% 이하 - Baseline: Logistic Regression - 고도화: 정형데이터+뉴스텍스트 멀티모달 (BERT Fine-tuning) - 평가: Recall, Precision, F1, ROC-AUC, PR-AUC	자산배분 비중 계산 - 목적함수: 수익률 − λ · 위험 − γ · 급락위험 - 제약: $\Sigma w_i=1$, 개별종목 ≤ 30% - 현금비중 하한을 위험성향에 따라 조정 - Markowitz → Risk Parity / 하방위험으로 고도화	해석 · 설명 (XAI) - 뉴스 · 공시 → sentiment · impact · risk_score - event_type · time_horizon 등 구조화 - Classification 판단근거 + Optimization 제약조건까지 해석 (SHAP/IG/Ablation 기반) - 사용자가 이해할 수 있는 추천 사유 작성

06 · ADVANCED DIRECTION

고도화 방향 — Multimodal Classification & XAI

※ 중간발표 피드백 반영 — Classification 차별성 강화 + GPT가 분석 과정을 함께 이해하는 구조 설계

① Multimodal Classification

- 정형데이터(가격 · 재무 · 수급) feature + 뉴스 텍스트를 함께 입력
- 뉴스: BERT/Transformer 오픈소스 사전학습 모델을 Fine-tuning해 임베딩 추출
- 정형 feature와 뉴스 임베딩을 결합(concat/attention)해 급락확률 예측
- 기존 Logistic Regression · RF · XGBoost는 정형 데이터 branch의 baseline으로 유지

② End-to-End 구조 & XAI

- Classification의 판단 근거(feature importance 등)를 다음 단계로 함께 전달
- Optimization에서 사용한 변수 · 제약조건도 GPT가 함께 참고
- GPT를 결과만 받는 설명 챗봇이 아닌, 과정을 이해하는 XAI 인터페이스로 재설계
- Classification → Optimization → 설명을 하나의 End-to-End 파이프라인으로 연결

AS-IS	TO-BE
정형데이터 → Classification → Optimization → GPT (결과만 전달받아 설명)	정형데이터+뉴스(BERT) 멀티모달 → Classification 판단근거 + Optimization 제약조건 → GPT (SHAP · IG · Ablation 기반 과정 이해 설명 · XAI)

07 · XAI IMPLEMENTATION

XAI 구현 방법

Classification이 정형 데이터 branch와 뉴스 텍스트 branch로 나뉘는 멀티모달 구조이기 때문에, 각 branch 성격에 맞는 설명 기법을 따로 적용하고 그 결과를 합쳐서 GPT에게 전달합니다.

대상	질문	방법	역할
정형 데이터	어떤 feature가 급락확률에 얼마나 영향을 줬나	SHAP	가격 · 재무 · 수급 등 각 feature의 기여도를 %로 산출
뉴스 텍스트	뉴스의 어떤 단어 · 표현이 영향을 줬나	Integrated Gradients	BERT 입력 임베딩 기준 토큰별 중요도 계산
뉴스 단위	뉴스 하나가 없었다면 결과가 얼마나 달라졌나	Ablation	뉴스 1건 제거 후 재추론해 확률 변화(delta) 계산

통합 흐름

세 방법의 결과는 `ai/explain/aggregate.py`에서 Optimization 제약조건과 함께 하나의 JSON 컨텍스트로 합쳐지고, `ai/explain/gpt_explainer.py`가 이 컨텍스트를 GPT에 전달해 최종 추천 사유를 생성합니다. 모델 내부 수치를 그대로 나열하지 않고, 어떤 정형 요인과 어떤 뉴스가 왜 중요했는지 자연어로 설명하는 것이 목표입니다.

단계	함수	설명
1	shap_explainer.explain_structured()	정형 데이터 영향 (SHAP)
2	integrated_gradients.explain_news_tokens()	뉴스 중요 표현 (Integrated Gradients)
3	ablation.ablate_news()	뉴스 1건 제거 시 변화 (Ablation)
4	aggregate.build_explanation_context()	위 3개 + Optimization 결과 통합
5	gpt_explainer.generate_explanation()	최종 추천 사유 생성

08 · OUTPUT & VALIDATION

최종 산출물 & 검증 방법

추천 포트폴리오 예시

종목	비중	선정 사유
A전자	25%	낮은 급락확률 + 안정적 재무지표
B화학	20%	업종 분산 및 중기 성장성
C통신	15%	낮은 변동성, 배당수익률 우수
현금성 자산	10%	위험성향 반영 방어 비중
기타 종목	30%	최적화 결과에 따른 분산 배분

※ 실제 데이터 · 모델 결과가 아닌, 화면 구성을 보여주기 위한 예시

백테스트 — Baseline 대비 검증

구분	설명
Baseline	시장 추종 / 동일비중 배분 (급락위험 미반영)
Proposed	급락확률 · 위험성향 반영 포트폴리오 최적화

평가지표 — 누적수익률, Sharpe Ratio, MDD(최대낙폭), 급락구간 방어력

09 · ROADMAP

개발 로드맵 (한 학기)

Phase	주제	작업
Phase 1	데이터 인프라	API 연동 및 원천데이터 적재 · PostgreSQL 스키마 설계
Phase 2	Feature & 모델링	Feature Engineering 파이프라인 · Classification 학습·평가
Phase 3	최적화 & 서비스화 & XAI	Portfolio Optimization 구현 · React·Vercel 서비스화 · SHAP/IG/Ablation 연결
Phase 4	검증 & 발표	Baseline 대비 백테스트 · 결과 분석 및 발표 준비

※ Phase 1의 한국투자증권 API 인증·단일 종목 요청 확인은 이미 완료.

레포 구조

db → ai(ingestion → features/labeling → classification → explain → optimization) → backend/frontend 순서로 개발합니다.

```
ai-stock-assistant/
├── README.md, .gitignore, .env.example
├── conftest.py
├── docs/architecture.md, docs/dev_reference.pdf
├── db/
│   ├── migrations/
│   │   ├── 0001_init_raw_tables.sql
│   │   ├── 0002_add_explain_tables.sql
│   │   └── 0003_add_label_crash.sql
│   ├── schema.md
│   └── seed/
├── ai/
│   ├── ingestion/              (kis_price / opendart_filing / naver_news / common / run_ingest)
│   ├── features/
│   ├── labeling/
│   │   └── build_crash_label.py            급락 정답 레이블(y) 생성
│   ├── classification/
│   │   ├── structured/     (Logistic Regression / RF / XGBoost baseline)
│   │   ├── text_bert/      (BERT/Transformer fine-tuning)
│   │   ├── fusion/           (정형 + 뉴스 임베딩 결합)
│   │   ├── split.py                                  train/test 날짜 기준 분할
│   │   ├── tests/test_split.py             겹침·역전 자동 검증
│   │   └── requirements.txt
│   ├── explain/
│   │   ├── shap_explainer.py                 SHAP
│   │   ├── integrated_gradients.py       Integrated Gradients
│   │   ├── ablation.py                           Ablation
│   │   ├── aggregate.py                        3개 결과 + optimization 통합
│   │   ├── gpt_explainer.py                  GPT 추천 사유 생성
│   │   ├── run_explain.py                      엔트리포인트
│   │   └── requirements.txt
│   └── optimization/
├── backend/              (FastAPI, 추후)
├── frontend/              (React / Vercel, 추후)
└── .github/workflows/ci.yml
```

11 · DB SCHEMA

DB 스키마 요약

1차 — raw 테이블 (0001_init_raw_tables.sql)

테이블	설명
stock_master	KOSPI 종목 마스터
price_daily	일별 시세 · 수급
financial_statement	재무제표
disclosure	공시 원문 메타
news_raw	뉴스 원문

2차 — classification + XAI 테이블 (0002_add_explain_tables.sql)

테이블	설명	대응 방법
classification_result	종목 · 시점별 급락확률 예측 결과	—
feature_importance	정형 feature별 기여도	SHAP
news_token_importance	뉴스 단어별 중요도	Integrated Gradients
news_ablation	뉴스 1건 제거 시 확률 변화	Ablation
explanation_log	GPT가 생성한 최종 추천 사유	—

3차 — 레이블 테이블 (0003_add_label_crash.sql)

테이블	설명	생성 코드
label_crash	종목 · 기준일별 급락 정답 레이블 (5거래일 내 종가 -10% 이하)	ai/labeling/build_crash_label.py

feature_importance 등 classification 결과 테이블과는 따로 뒀습니다. 레이블은 기준일 이후 가격을 봐야 만들어지는 값이라, feature 생성 코드와 섞이지 않게 했습니다.

추후 추가 예정 — news_structured, feature_store, portfolio_result (ai 단계 진행하면서 출력 형태가 확정되는 대로 migration 추가)

핵심 요약

> “ 이 프로젝트는 주가를 맞히는 예측 모델이 아니라, 급락 위험을 정량화하고 그 정보를 실제 자산배분 의사결정에 반영하는 것이 핵심입니다. ”

Classification은 위험을 판단하고, Portfolio Optimizer는 그 판단을 실행 가능한 비중으로 바꾸며, GPT는 SHAP · Integrated Gradients · Ablation으로 뽑아낸 근거를 사람이 이해할 수 있는 설명으로 연결합니다.

다음 회의에서 결정할 사항

- 급락의 정의 (하락률 · 기간) — 현재 코드 기본값은 5거래일 내 종가 -10% 이하
- Classification 평가 방법
- Portfolio 알고리즘 선정
- SHAP/Integrated Gradients/Ablation 결과를 GPT 프롬프트에 넣을 구체적인 포맷
- train/test 분할 기준일 (ai/classification/split.py의 TRAIN_END_DATE) 확정